



[Κ17] Υπολογιστική Θεωρία Μηχανικής Μάθησης

Θεωρητικές Ασκήσεις

Ονοματεπώνυμο: Χολέβας Δημήτριος

Ακαδημαϊκό Έτος: 2024-25

1η Θεωρητική Άσκηση

(Εκτίμηση Κατάταξης)

Αρχικά, αυτό που έχουμε να κάνουμε είναι να ορίσουμε $rank(x)$ ως τη θέση του x στη φθίνουσα ταξινόμηση της λίστας. Στην ουσία θα ισχύει πως το μέγιστο στοιχείο έχει $rank$ 1, το δεύτερο μέγιστο $rank$ 2, κ.ο.κ. Ακολουθούμε τα παρακάτω βήματα:

1. Λαμβάνουμε τυχαία ένα δείγμα μεγέθους m από τη λίστα $x_1, \dots, x_n$, επιλέγοντας στοιχεία με επαναλήψεις (δηλαδή με αντικατάσταση).
2. Ταξινομούμε τα δείγματα κατά φθίνουσα σειρά, ώστε τα μεγαλύτερα να έρχονται πρώτα.
3. Εντοπίζουμε το στοιχείο που βρίσκεται στη θέση $\lfloor \frac{km}{n} \rfloor$ στη ταξινομημένη υπολίστα και το επιστρέφουμε ως εκτίμηση.

Ανάλυση Σφάλματος

Αξιοποιούμε την ιδιότητα ότι η εμπειρική κατανομή που προκύπτει από ένα τυχαίο δείγμα προσεγγίζει την πραγματική κατανομή του πληθυσμού. Για να ποσοτικοποιήσουμε αυτή την απόκλιση, χρησιμοποιούμε την ανισότητα *DvoretzkyΓKieferΓWolfowitz (DKW)*. Σύμφωνα με αυτήν, αν πάρουμε m ανεξάρτητα δείγματα $X_1, \dots, X_m$ από κατανομή με συνάρτηση κατανομής F , τότε η εμπειρική κατανομή F_m ικανοποιεί:

$$\Pr \left[\sup_x |F_m(x) - F(x)| > \varepsilon \right] \leq 2e^{-2m\varepsilon^2}$$

Αυτό μας εξασφαλίζει ότι η μέγιστη κατακόρυφη απόκλιση μεταξύ $F_m(x)$ και $F(x)$ είναι μικρή με πιθανότητα τουλάχιστον $1 - \delta$.

Η συνάρτηση $F(x)$ εκφράζει το ποσοστό των στοιχείων της αρχικής λίστας που είναι μικρότερα ή ίσα από x . Επομένως, η θέση k αντιστοιχεί περίπου στο ποσοστό k/n ως προς την πραγματική κατανομή. Αντίστοιχα, στο δείγμα μεγέθους m , η θέση $k \cdot m/n$ αποτελεί μια φυσική εκτίμηση αυτής της ποσοστιαίας μονάδας.

Στόχος μας είναι να εγγυηθούμε ότι το στοιχείο που επιλέγουμε από το δείγμα έχει κατάταξη που προσεγγίζει το k στην αρχική λίστα. Στην ουσία θέλουμε να ισχύει το εξής:

$$\left| \frac{\text{rank}(x)}{n} - \frac{k}{n} \right| \leq \varepsilon \cdot \frac{k}{n} \Rightarrow |\text{rank}(x) - k| \leq \varepsilon k$$

Με αυτόν τον τρόπο σιγουρεύουμε ότι η κατάταξη του εκτιμώμενου στοιχείου βρίσκεται εντός του διαστήματος $[(1 - \varepsilon)k, (1 + \varepsilon)k]$ με υψηλή πιθανότητα.

Υπολογίζουμε το μέγεθος του δείγματος m

Από την DKW , έχουμε:

$$\Pr \left[\sup_x |F_m(x) - F(x)| \leq \varepsilon \right] \geq 1 - \delta \Rightarrow 2e^{-2m\varepsilon^2} \leq \delta \Rightarrow m \geq \frac{1}{2\varepsilon^2} \log \left(\frac{2}{\delta} \right)$$

Με βάση το παραπάνω, παρατηρούμε πως αν επιλέξουμε:

$$m = O \left(\frac{1}{\varepsilon^2} \log \frac{1}{\delta} \right)$$

τότε με πιθανότητα τουλάχιστον $1 - \delta$, θα μας επιστραφεί ένα x τέτοιο ώστε να ισχύει

$$(1 - \varepsilon)k \leq \text{rank}(x) \leq (1 + \varepsilon)k$$