



[Κ17] Υπολογιστική Θεωρία Μηχανικής Μάθησης

Θεωρητικές Ασκήσεις

Ονοματεπώνυμο: Χολέβας Δημήτριος

Ακαδημαϊκό Έτος: 2024-25

2η Θεωρητική Άσκηση

(Καταμέτρηση μέσω Ερωτημάτων)

Ερώτημα α

Με βάση την συμβουλή της εκφώνησης που μας δόθηκε, δημιουργούμε ένα τυχαίο υποσύνολο $Q \subseteq \{1, \dots, n\}$ έτσι ώστε κάθε στοιχείο i να περιλαμβάνεται στο Q με ανεξάρτητη πιθανότητα $1/k$. Ορίζουμε τον δείκτη:

$$Z = \mathbb{I}[S \cap Q \neq \emptyset]$$

όπου το Z παίρνει τιμή 1 όταν υπάρχει τουλάχιστον ένα κοινό στοιχείο μεταξύ των S και Q , και 0 διαφορετικά. Έστω ότι $|S| = s$. Τότε η πιθανότητα το υποσύνολο Q να μην περιέχει κανένα στοιχείο του S είναι:

$$\Pr[Z = 0] = \left(1 - \frac{1}{k}\right)^s \Rightarrow \Pr[Z = 1] = 1 - \left(1 - \frac{1}{k}\right)^s$$

Διακρίνουμε δύο βασικές περιπτώσεις, ανάλογα με τη σχέση του s με το k :

Περίπτωση 1: Αν $s \leq k$, τότε η πιθανότητα το Q περιέχει τουλάχιστον ένα στοιχείο του S και ισχύει το εξής:

$$\Pr[Z = 1] \leq 1 - \left(1 - \frac{1}{k}\right)^k \leq 1 - \frac{1}{e}$$

Περίπτωση 2: Αν $s \geq (1 + \varepsilon)k$, τότε το πλήθος των στοιχείων του S είναι σημαντικά μεγαλύτερο, οπότε η πιθανότητα επιτυχίας αυξάνεται ως εξής:

$$\Pr[Z = 1] \geq 1 - \left(1 - \frac{1}{k}\right)^{(1+\varepsilon)k} \geq 1 - \frac{1}{e^{1+\varepsilon}}$$

Επομένως, υπάρχει σταθερή απόσταση ανάμεσα στις δύο πιθανότητες:

$$c = \frac{1}{e^{1+\varepsilon}} - \frac{1}{e}$$

Προκειμένου να διακρίνουμε αξιόπιστα τις δύο περιπτώσεις, επαναλαμβάνουμε τη διαδικασία t φορές και ορίζουμε τον εμπειρικό μέσο:

$$\hat{p} = \frac{1}{t} \sum_{i=1}^t Z_i$$

Εφόσον τα Z_i είναι ανεξάρτητα μεταξύ τους και ανήκουν στο διάστημα $[0, 1]$, μπορούμε να εφαρμόσουμε την ανισότητα *Hoeffding*:

$$\Pr[|\hat{p} - \mathbb{E}[Z]| \geq \alpha] \leq 2e^{-2t\alpha^2}$$

Θέτουμε $\alpha = \frac{c}{2}$, με σκοπό να ξεχωρίσουμε με υψηλή βεβαιότητα τις δύο περιπτώσεις. Τότε, για δεδομένο σφάλμα δ , απαιτούμε:

$$2e^{-2t\alpha^2} \leq \delta \quad \Rightarrow \quad e^{-2t\alpha^2} \leq \frac{\delta}{2} \quad \Rightarrow \quad -2t\alpha^2 \leq \ln\left(\frac{\delta}{2}\right)$$

Αντικαθιστούμε $\alpha = \frac{c}{2}$ και έχουμε:

$$t \geq \frac{1}{2(c/2)^2} \ln\left(\frac{2}{\delta}\right) = \frac{2}{c^2} \ln\left(\frac{2}{\delta}\right)$$

Επειδή $c = \Theta(\varepsilon)$, αυτό συνεπάγεται ότι ο αριθμός των απαιτούμενων επαναλήψεων θα είναι:

$$t = O\left(\frac{1}{\varepsilon^2} \log \frac{1}{\delta}\right) = O\left(\frac{\log(1/\delta)}{\varepsilon^2}\right)$$

Συμπέρασμα: Με βάση τα παραπάνω, παρατηρούμε πως μας αρκούν $O\left(\frac{\log(1/\delta)}{\varepsilon^2}\right)$ ερωτήματα ώστε, με πιθανότητα τουλάχιστον $1 - \delta$, να μπορούμε να ξεχωρίσουμε με αξιοπιστία αν ισχύει $|S| \leq k$ ή $|S| \geq (1 + \varepsilon)k$.

Ερώτημα β

Προκειμένου να πετύχουμε το ζητούμενο σε αυτό το ερώτημα, αξιοποιούμε τα βήματα που αναλύσαμε στο προηγούμενο ερώτημα (α). Εκεί δείξαμε ότι με $O\left(\frac{\log(1/\delta)}{\varepsilon^2}\right)$ ερωτήματα μπορούμε, με πιθανότητα τουλάχιστον $1 - \delta$, να ελέγξουμε για κάθε δοσμένο k αν ισχύει $|S| \leq k$ ή $|S| \geq (1 + \varepsilon)k$. Με βάση αυτά λοιπόν, εφαρμόζουμε δυαδική αναζήτηση στο διάστημα $[1, n]$ για να εντοπίσουμε το μικρότερο k για το οποίο με βάση τα βήματα του ερωτήματος (α) ισχύει: $|S| \leq (1 + \varepsilon)k$.

Η αναζήτηση γίνεται ως εξής:

- Σε κάθε βήμα επιλέγουμε ένα k στο τρέχον διάστημα και εφαρμόζουμε τη διαδικασία του (α) για να ελέγξουμε αν $|S| \leq k$ ή $|S| \geq (1 + \varepsilon)k$.
- Αν το αποτέλεσμα δείχνει ότι $|S| \leq k$, μετακινούμε το δεξί άκρο της αναζήτησης προς τα αριστερά.
- Αν το αποτέλεσμα δείχνει ότι $|S| \geq (1 + \varepsilon)k$, μετακινούμε το αριστερό άκρο της αναζήτησης προς τα δεξιά.

Η παραπάνω διαδικασία επαναλαμβάνεται μέχρι το διάστημα να περιοριστεί αρκετά ώστε να καταλήξουμε σε τιμή $\hat{s}$ τέτοια ώστε να ισχύει:

$$\hat{s} \leq |S| \leq (1 + \varepsilon)\hat{s}$$

Ο συνολικός αριθμός βημάτων της δυαδικής αναζήτησης είναι $O(\log n)$, αφού κάθε έλεγχος μειώνει το διάστημα στο μισό. Σε κάθε τέτοιο βήμα καλούμε τα βήματα του (α) , όπου:

$$O\left(\frac{1}{\varepsilon^2} \log \frac{1}{\delta}\right) = O\left(\frac{\log(1/\delta)}{\varepsilon^2}\right)$$

ερωτήματα για επιτυχία με πιθανότητα τουλάχιστον $1 - \delta$

Επομένως, ο συνολικός αριθμός ερωτημάτων είναι:

$$O\left(\frac{1}{\varepsilon^2} \log n \cdot \log \frac{1}{\delta}\right)$$

Αν θέλουμε η συνολική πιθανότητα αποτυχίας να είναι το πολύ $1/3$ (ώστε η συνολική πιθανότητα επιτυχίας να είναι τουλάχιστον $2/3$), αρκεί να θέσουμε $\delta = \frac{1}{3 \log n}$ ώστε να εφαρμόσουμε ένωση πιθανοτήτων για τα $O(\log n)$ βήματα

Με βάση τα παραπάνω, έχουμε:

$$\log \frac{1}{\delta} = \log(3 \log n) = O(\log \log n) \Rightarrow \text{συνολικά } O\left(\frac{1}{\varepsilon^2} \log n \cdot \log \log n\right) \text{ ερωτήματα.}$$

Συμπέρασμα: Εν κατακλείδι, χρησιμοποιώντας δυαδική αναζήτηση με βάση τα βήματα του ερωτήματος (α) , μπορούμε να υπολογίσουμε έναν εκτιμητή $\hat{s}$ για το πλήθος των στοιχείων του S , έτσι ώστε με πιθανότητα τουλάχιστον $2/3$ να ισχύει:

$$\hat{s} \leq |S| \leq (1 + \varepsilon)\hat{s}$$

με συνολικό αριθμό ερωτημάτων λογαριθμικό ως προς το n .

Ερώτημα γ

Γνωρίζοντας ότι $|S| = s$, ακολουθούμε την παρακάτω στρατηγική, με βάση και τη συμβουλή της εκφώνησης:

1. Δημιουργούμε τυχαία ένα υποσύνολο $Q \subseteq \{1, \dots, n\}$, στο οποίο κάθε στοιχείο i περιλαμβάνεται με ανεξάρτητη πιθανότητα $1/s$.
2. Ελέγχουμε αν το Q περιέχει ακριβώς ένα στοιχείο από το S , δηλαδή αν $|S \cap Q| = 1$
3. Αν ισχύει αυτό, επιστρέφουμε το μοναδικό στοιχείο του $S \cap Q$ ως δείγμα. Διαφορετικά, επαναλαμβάνουμε τη διαδικασία με νέο τυχαίο Q .

Η πιθανότητα το Q να περιέχει ακριβώς ένα στοιχείο του S είναι:

$$\Pr[|S \cap Q| = 1] = s \cdot \frac{1}{s} \cdot \left(1 - \frac{1}{s}\right)^{s-1} = \left(1 - \frac{1}{s}\right)^{s-1} \geq \frac{1}{e}$$

Άρα, με σταθερή πιθανότητα (τουλάχιστον $1/e$), το Q περιέχει ακριβώς ένα στοιχείο του S , και ο αναμενόμενος αριθμός επαναλήψεων μέχρι να συμβεί αυτό είναι $O(1)$.

Για να εντοπίσουμε το μοναδικό στοιχείο του $S \cap Q$, όταν αυτό υπάρχει, εφαρμόζουμε **δυαδική αναζήτηση** στα στοιχεία του Q ως εξής:

- Χωρίζουμε το Q σε δύο ίσα υποσύνολα Q_1 και Q_2 .
- Ρωτάμε αν $Q_1 \cap S \neq \emptyset$.
- Αν ναι, συνεχίζουμε τη διαδικασία στο Q_1 , αλλιώς στο Q_2 .
- Επαναλαμβάνουμε αναδρομικά μέχρι να εντοπίσουμε το στοιχείο.

Καθώς το μέγεθος του Q είναι αναμενόμενα $O(1)$, η δυαδική αναζήτηση απαιτεί $O(\log n)$ ερωτήματα.

Συμπέρασμα: Ο αναμενόμενος αριθμός ερωτημάτων για να κάνουμε δειγματοληψία ομοιόμορφα ένα τυχαίο στοιχείο από το S είναι: $O(\log n)$