



[Κ17] Υπολογιστική Θεωρία Μηχανικής Μάθησης

Θεωρητικές Ασκήσεις

Ονοματεπώνυμο: Χολέβας Δημήτριος

Ακαδημαϊκό Έτος: 2024-25

3η Θεωρητική Άσκηση

(Απόσταση *Kolmogorou*)

Ερώτημα α

Στόχος μας σε αυτό το ερώτημα είναι να κατασκευάσουμε έναν εκτιμητή $\hat{p}$ της άγνωστης κατανομής p , ώστε με πιθανότητα τουλάχιστον $1 - \delta$ να ισχύει:

$$d_K(\hat{p}, p) \leq \varepsilon$$

Για τον σκοπό αυτό, ακολουθούμε τα εξής βήματα:

- Παίρνουμε m ανεξάρτητα δείγματα $X_1, X_2, \dots, X_m$ από την κατανομή p .
- Για κάθε $i \in [n]$, ορίζουμε την εμπειρική συνάρτηση κατανομής ως:

$$\hat{F}_p(i) = \frac{1}{m} \sum_{j=1}^m \mathbb{I}[X_j \leq i]$$

- Ορίζουμε $\hat{p}(i) = \hat{F}_p(i) - \hat{F}_p(i-1)$, με $\hat{F}_p(0) = 0$.

Για να δείξουμε ότι αυτός ο εκτιμητής ικανοποιεί το ζητούμενο, εφαρμόζουμε την **Ανισότητα Dvoretzky – Kiefer – Wolfowitz (DKW)**:

$$\Pr \left[\sup_i |\hat{F}_p(i) - F_p(i)| > \varepsilon \right] \leq 2e^{-2m\varepsilon^2}$$

Θέλουμε η πιθανότητα να είναι μικρότερη ή ίση με δ , άρα μας αρκεί:

$$2e^{-2m\varepsilon^2} \leq \delta \quad \Rightarrow \quad m \geq \frac{1}{2\varepsilon^2} \log \left(\frac{2}{\delta} \right)$$

Συμπέρασμα: Με $O \left(\frac{\log(1/\delta)}{\varepsilon^2} \right)$ δείγματα μπορούμε, με πιθανότητα τουλάχιστον $1 - \delta$, να προσεγγίσουμε την κατανομή p σε απόσταση *Kolmogorou* το πολύ ε . Η εκτίμησή μας βέβαια δεν εξαρτάται από το πλήθος n των τιμών που μπορεί να πάρει η κατανομή, αφού η απόσταση *Kolmogorou* εξαρτάται μόνο από το μέγιστο της διαφοράς των *CDFs* και όχι από το n .

Ερώτημα β

Σκοπός μας είναι να δείξουμε ότι οποιοσδήποτε αλγόριθμος που εκτιμά μια κατανομή p σε απόσταση $Kolmogorou$ τουλάχιστον ε , με πιθανότητα τουλάχιστον $1 - \delta$, απαιτεί τουλάχιστον:

$$\Omega\left(\frac{1}{\varepsilon^2} \log \frac{1}{\delta}\right) = \Omega\left(\frac{\log(1/\delta)}{\varepsilon^2}\right) \text{ δείγματα.}$$

Για να αποδείξουμε αυτό το κατώτερο όριο, μπορούμε να βασιστούμε σε θεμελιώδη εργαλεία της στατιστικής μάθησης και πληροφορίας:

- Το **Θεώρημα Le Cam**, το οποίο συγκρίνει δύο υποθέσεις H_0, H_1 που αντιστοιχούν σε δύο κατανομές p και q με απόσταση $Kolmogorou$ τουλάχιστον ε , και παρέχει κάτω φράγμα στο σφάλμα κάθε στατιστικού ελέγχου μεταξύ τους με βάση τη συνολική μεταβολή (*total variation*).
- Την **Ανισότητα Fano**, η οποία συσχετίζει το ελάχιστο σφάλμα ενός ταξινομητή ανάμεσα σε πολλές πιθανές κατανομές με τη μεταξύ τους απόσταση (σε KL ή TV) και την απαιτούμενη πληροφορία (εντροπία).

Ειδικότερα, θεωρούμε μια οικογένεια από N κατάλληλα κατασκευασμένες διακριτές κατανομές $\{p_1, \dots, p_N\}$ στο $[n]$ με τις εξής ιδιότητες:

- Για κάθε $i \neq j$, ισχύει $d_K(p_i, p_j) \geq \varepsilon$
- Η σχετική εντροπία $D_{KL}(p_i \| p_j)$ είναι μικρή, ώστε να μην είναι εύκολα διακριτές

Η εφαρμογή της Ανισότητας *Fano* μάς οδηγεί στο εξής κατώτερο όριο για τον αριθμό δειγμάτων m που απαιτούνται ώστε να διακρίνουμε με πιθανότητα τουλάχιστον $1 - \delta$ μεταξύ αυτών των κατανομών:

$$m \geq \Omega\left(\frac{1}{\varepsilon^2} \log \frac{1}{\delta}\right) = \Omega\left(\frac{\log(1/\delta)}{\varepsilon^2}\right)$$

Εναλλακτικά, μπορούμε να εφαρμόσουν το Θεώρημα *Le Cam* για να συγκρίνουμε δύο διακριτές κατανομές p και q με $d_K(p, q) \geq \varepsilon$ και να δείξουμε ότι για να μειωθεί το σφάλμα διάκρισης κάτω από δ , απαιτούνται τουλάχιστον $\Omega\left(\frac{1}{\varepsilon^2} \log \frac{1}{\delta}\right) = \Omega\left(\frac{\log(1/\delta)}{\varepsilon^2}\right)$ δείγματα.

Συμπέρασμα: Το κατώτερο όριο αυτό επιβεβαιώνει ότι κάθε αλγόριθμος που επιτυγχάνει *Kolmogorou* σφάλμα ε με πιθανότητα τουλάχιστον $1 - \delta$, απαιτεί κατ' ελάχιστον:

$$\Omega\left(\frac{\log(1/\delta)}{\varepsilon^2}\right)$$

δείγματα. Συνεπώς, η προσέγγιση του ερωτήματος (α) είναι βέλτιστη κατά τάξη μεγέθους.

Ερώτημα γ

Σε αυτό το ερώτημα γνωρίζουμε ότι η συνάρτηση μάζας πιθανοτήτων $p : [n] \rightarrow [0, 1]$ είναι **μη αύξουσα**, δηλαδή για κάθε $i \in [n - 1]$ ισχύει $p(i) \geq p(i + 1)$. Στόχος μας είναι να διακρίνουν με πιθανότητα τουλάχιστον $1 - \delta$ αν η p είναι **ομοιόμορφη** ($p = U_n$) ή αν απέχει τουλάχιστον ε από την ομοιόμορφη ως προς την απόσταση **ολικής μεταβολής** ($d_{TV}(p, U_n) \geq \varepsilon$). Η απόσταση ολικής μεταβολής μεταξύ δύο κατανομών p και q δίνεται από:

$$d_{TV}(p, q) = \frac{1}{2} \sum_{i=1}^n |p(i) - q(i)|$$

Αξιοποιώντας το γεγονός ότι η p είναι μη αύξουσα, παρατηρούμε ότι αν διαφέρει από την ομοιόμορφη κατανομή, τότε είναι πολύ πιθανό η διαφορά να εντοπίζεται στα άκρα του διαστήματος: συγκεκριμένα, θα περιμένουμε $p(1) > \frac{1}{n}$ ανδ $p(n) < \frac{1}{n}$. Αυτό μας επιτρέπει να βασιστούμε μόνο στις εκτιμήσεις αυτών των δύο σημείων.

Ακολουθούμε τα παρακάτω βήματα:

1. Παίρνουμε m ανεξάρτητα δείγματα από την κατανομή p .
2. Εκτιμούμε τις τιμές των $p(1)$ και $p(n)$ ως ποσοστά συχνοτήτων στο δείγμα:

$$\hat{p}(1) = \frac{\text{“φορών που είδαμε 1”}}{m}, \quad \hat{p}(n) = \frac{\text{“φορών που είδαμε } n\text{”}}{m}$$

3. Υπολογίζουμε το άθροισμα των αποκλίσεων από την ομοιόμορφη:

$$T = \left| \hat{p}(1) - \frac{1}{n} \right| + \left| \hat{p}(n) - \frac{1}{n} \right|$$

4. Αν $T \geq \varepsilon$, απορρίπτουμε την υπόθεση ότι $p = U_n$. Διαφορετικά, αποδεχόμαστε ότι η κατανομή είναι (σχεδόν) ομοιόμορφη.

Για να διασφαλίσουμε ότι οι εμπειρικές τιμές $\hat{p}(1)$ ανδ $\hat{p}(n)$ είναι αρκετά κοντά στις πραγματικές τιμές με υψηλή πιθανότητα, εφαρμόζουμε την **ανισότητα του Hoeffding**:

$$\Pr [|\hat{p}(i) - p(i)| \geq \varepsilon] \leq 2e^{-2m\varepsilon^2}$$

Θέλουμε αυτή η πιθανότητα να είναι το πολύ $\delta/2$ για καθένα από τα $i = 1, n$, ώστε συνολικά η πιθανότητα λάθους να είναι μικρότερη από δ . Άρα, αρκεί να επιλέξουμε:

$$m = O\left(\frac{\log(1/\delta)}{\varepsilon^2}\right)$$

Συμπέρασμα: Με βάση τη μονοτονία της p , μπορούμε να διακρίνουμε τις δύο περιπτώσεις με πιθανότητα τουλάχιστον $1 - \delta$ χρησιμοποιώντας μόνο $O\left(\frac{\log(1/\delta)}{\varepsilon^2}\right)$ δείγματα. Η πολυπλοκότητα αυτή είναι βέλτιστη με βάση τα δείγματα όπως δείξαμε και στα προηγούμενα ερωτήματα.