



[Κ17] Υπολογιστική Θεωρία Μηχανικής Μάθησης

Θεωρητικές Ασκήσεις

Ονοματεπώνυμο: Χολέβας Δημήτριος

Ακαδημαϊκό Έτος: 2024-25

4η Θεωρητική Άσκηση (Εκμάθηση Ορθογωνίων)

Ερώτημα α

Στόχος μας είναι να δείξουμε ότι στην *realizable* περίπτωση, ένας αλγόριθμος που κατασκευάζει το μικρότερο *axis – aligned* ορθογώνιο που περιέχει τα θετικά παραδείγματα είναι *Empirical Risk Minimizer (ERM)*. Προκειμένου να το πετύχουμε αυτό, ακολουθούμε τα παρακάτω βήματα:

1. Από το δείγμα $S = \{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$, κρατάμε όλα τα παραδείγματα με ετικέτα $+1$.
2. Για κάθε διάσταση $i \in [d]$, υπολογίζουμε τα άκρα του μικρότερου ορθογωνίου που περιέχει όλα τα θετικά παραδείγματα:

$$\hat{a}_i = \min\{x_i^{(j)} : y^{(j)} = +1\}, \quad \hat{b}_i = \max\{x_i^{(j)} : y^{(j)} = +1\}$$

3. Επιστρέφουμε την υπόθεση $h_{\hat{a}, \hat{b}}$.

Εφόσον το πρόβλημα είναι *realizable*, υπάρχει υπόθεση h^* που ταξινομεί όλα τα παραδείγματα σωστά. Άρα όλα τα θετικά παραδείγματα βρίσκονται μέσα στο πραγματικό ορθογώνιο $[a^*, b^*]$. Το ορθογώνιο $[\hat{a}, \hat{b}]$ είναι υποσύνολο αυτού, καθώς κατασκευάζεται με βάση τα θετικά παραδείγματα. Επομένως, το $h_{\hat{a}, \hat{b}}$ έχει **εμπειρικό σφάλμα μηδέν**.

Συμπέρασμα: Ο αλγόριθμος διαλέγει την υπόθεση που ταιριάζει σωστά με τα δεδομένα του δείγματος, χωρίς να κάνει λάθη και επομένως λειτουργεί ως *ERM*.

Ερώτημα β

Στόχος μας είναι να δείξουμε ότι ο αλγόριθμος είναι (ϵ, δ) -*realizable PAC learner* με:

$$m_H^{PAC} = O\left(\frac{d}{\epsilon} \log\left(\frac{d}{\delta}\right)\right)$$

Ξεκινάμε από την υπόθεση ότι ο αλγόριθμος επιστρέφει ένα ορθογώνιο $\hat{R} = [\hat{a}, \hat{b}]$, το οποίο είναι υποσύνολο του πραγματικού ορθογωνίου $R^* = [a^*, b^*]$.

Το σφάλμα του ταξινομητή οφείλεται σε σημεία που ανήκουν στο R^* αλλά βρίσκονται εκτός του $\hat{R}$ — δηλαδή, στα άκρα που «κόπηκαν» λόγω απουσίας θετικών δειγμάτων σε αυτά τα σημεία. Για κάθε διάσταση $i \in [d]$, ορίζουμε τα διαστήματα:

$$(a_i^*, \hat{a}_i) \quad \text{και} \quad (\hat{b}_i, b_i^*)$$

τα οποία περιγράφουν τα άκρα του R^* που δεν καλύπτονται από το $\hat{R}$. Έχουμε συνολικά $2d$ τέτοια διαστήματα. Αν σε κάθε ένα από αυτά τα διαστήματα πέσει τουλάχιστον ένα θετικό δείγμα, τότε η διαφορά $R^* \setminus \hat{R}$ θα έχει συνολικό μέτρο μικρότερο από ε .

Ας υποθέσουμε ότι για κάθε $i \in [d]$ ισχύει:

$$\Pr[x_i \in (a_i^*, \hat{a}_i)] < \frac{\varepsilon}{2d}$$

και το ίδιο για τα δεξιά άκρα. Η πιθανότητα να μην πέσει κανένα δείγμα σε τέτοιο διάστημα είναι:

$$\left(1 - \frac{\varepsilon}{2d}\right)^m \leq \exp\left(-\frac{m\varepsilon}{2d}\right)$$

Θέλουμε αυτή η πιθανότητα να είναι μικρότερη από $\delta/(2d)$ ώστε, με χρήση της ένωσης πιθανοτήτων, να εγγυηθούμε συνολική πιθανότητα λάθους το πολύ δ :

$$2d \cdot \frac{\delta}{2d} = \delta$$

Λύνουμε την ανίσωση:

$$\exp\left(-\frac{m\varepsilon}{2d}\right) \leq \frac{\delta}{2d} \quad \Rightarrow \quad m \geq \frac{2d}{\varepsilon} \log\left(\frac{2d}{\delta}\right)$$

Συμπέρασμα: Αν πάρουμε δείγμα μεγέθους:

$$m_H^{\text{PA}^*} = O\left(\frac{d}{\varepsilon} \log\left(\frac{d}{\delta}\right)\right)$$

τότε με πιθανότητα τουλάχιστον $1 - \delta$ ο αλγόριθμος θα επιστρέφει υπόθεση με σφάλμα μικρότερο από ε και επομένως είναι πράγματι (ε, δ) -realizable PAC learner.

Ερώτημα γ

Στόχος μας σε αυτό το ερώτημα είναι να υπολογίσουμε τη διάσταση $VC(H)$ της υποθεσιακής κλάσης H . Η διάσταση VC είναι το μέγιστο πλήθος σημείων για τα οποία μπορούμε να πραγματοποιήσουμε **όλους τους δυνατούς διαχωρισμούς** σε θετικά και αρνητικά παραδείγματα, χρησιμοποιώντας υποθέσεις από την H . Δηλαδή, ψάχνουμε πόσα σημεία μπορούμε να διαχωρίσουμε με κάθε πιθανό τρόπο, αν μας επιτρέπεται να χρησιμοποιούμε ορθογώνια ευθυγραμμισμένα με τους άξονες.

Αρχικά, θέλουμε να δείξουμε ότι η κλάση H μπορεί να διαχωρίσει με όλους τους δυνατούς τρόπους ένα σύνολο $2d$ κατάλληλα τοποθετημένων σημείων. Χρησιμοποιούμε d διαστάσεις. Για κάθε διάσταση $i \in \{1, 2, \dots, d\}$, επιλέγουμε δύο σημεία:

- Ένα σημείο $x^{(i,\min)}$ που έχει πολύ μικρή τιμή στην i -οστή διάσταση, ενώ στις υπόλοιπες διαστάσεις έχει σταθερές, μεσαίες τιμές.
- Ένα σημείο $x^{(i,\max)}$ που έχει πολύ μεγάλη τιμή στην i -οστή διάσταση, και πάλι σταθερές τιμές στις υπόλοιπες.

Έτσι, φτιάχνουμε συνολικά $2d$ σημεία, δύο για κάθε διάσταση. Ο λόγος που επιλέγουμε τέτοια σημεία είναι ότι μπορούμε, μέσω ενός ορθογωνίου με πλευρές παράλληλες στους άξονες, να περιλαμβάνουμε ή να αποκλείουμε επιλεκτικά κάθε τέτοιο σημείο, ρυθμίζοντας κατάλληλα τα όρια a_i και b_i σε κάθε διάσταση. Με άλλα λόγια, για κάθε πιθανό τρόπο με τον οποίο μπορούμε να χαρακτηρίσουμε τα $2d$ σημεία ως θετικά ή αρνητικά, υπάρχει πάντα ένα ορθογώνιο από την κλάση H που περιλαμβάνει ακριβώς τα θετικά και αποκλείει τα αρνητικά.

Επομένως, η κλάση H μπορεί να διαχωρίσει όλους τους δυνατούς συνδυασμούς για αυτά τα $2d$ σημεία και άρα έχουμε:

$$VC(H) \geq 2d$$

Στη συνέχεια, θα δείξουμε ότι δεν είναι δυνατό να διαχωρίσουμε όλους τους πιθανούς συνδυασμούς θετικών και αρνητικών παραδειγμάτων αν προσθέσουμε ένα ακόμα σημείο, δηλαδή συνολικά $2d + 1$ σημεία.

Ο λόγος είναι ο εξής: κάθε ορθογώνιο από την κλάση H καθορίζεται πλήρως από $2d$ αριθμούς, τα a_i και b_i για κάθε διάσταση i . Δηλαδή, έχουμε $2d$ βαθμούς ελευθερίας για να επιλέξουμε ποια σημεία θα περιληφθούν μέσα στο ορθογώνιο και ποια θα αποκλειστούν. Αν προσθέσουμε ένα επιπλέον σημείο, τότε υπάρχει τουλάχιστον ένας τρόπος χαρακτηρισμού αυτών των $2d + 1$ σημείων που δεν μπορούμε να καλύψουμε με κανένα ορθογώνιο από την κλάση H . Το πρόβλημα είναι ότι δεν μπορούμε να περιλάβουμε ή να αποκλείσουμε ανεξάρτητα το επιπλέον σημείο χωρίς να επηρεάσουμε τη συμπερίληψη άλλων σημείων, λόγω των περιορισμών στη μορφή του ορθογωνίου.

Άρα δεν μπορούμε να διαχωρίσουμε όλους τους πιθανούς συνδυασμούς όταν έχουμε $2d + 1$ σημεία. Επομένως:

$$VC(H) < 2d + 1$$

Συμπέρασμα: Από τα παραπάνω, καταλήγουμε ότι η VC διάσταση της υποθεσιακής κλάσης H είναι:

$$VC(H) = 2d$$

Ερώτημα δ

Για να υπολογίσουμε τα βουνδς της δειγματικής πολυπλοκότητας, κάνουμε τα εξής:

Περίπτωση *realizable*: Υποθέτουμε ότι υπάρχει υπόθεση $h^* \in H$ που ταξινομεί σωστά όλα τα δείγματα (δηλαδή με μηδενικό σφάλμα). Θέλουμε ο αλγόριθμος να επιστρέφει υπόθεση με σφάλμα το πολύ ε ως προς την κατανομή, με πιθανότητα τουλάχιστον $1 - \delta$. Από τη θεωρία *PAC* γνωρίζουμε ότι:

$$m = O\left(\frac{VC(H)}{\varepsilon} \log \frac{1}{\delta}\right)$$

Από το προηγούμενο ερώτημα (γ), έχουμε ότι $VC(H) = 2d$ και επομένως:

$$m = O\left(\frac{d}{\varepsilon} \log \frac{1}{\delta}\right) = O\left(\frac{d}{\varepsilon} \log(d/\delta)\right)$$

Δηλαδή, για να πετύχουμε ακρίβεια ε με εμπιστοσύνη $1 - \delta$, αρκεί να πάρουμε αριθμό δειγμάτων που εξαρτάται γραμμικά από d και αντιστρόφως ανάλογα από το ε .

Περίπτωση *agnostic*: Εδώ δεν υποθέτουμε ότι υπάρχει υπόθεση στην H που ταξινομεί τέλεια τα δεδομένα. Στόχος μας είναι να επιστρέψουμε υπόθεση που έχει σφάλμα το πολύ ε μεγαλύτερο από το μικρότερο δυνατό σφάλμα που μπορεί να επιτευχθεί με υπόθεση της H . Σε αυτή την περίπτωση, με βάση τη θεωρία *PAC* έχουμε:

$$m = O\left(\frac{VC(H)}{\varepsilon^2} \log \frac{1}{\delta}\right)$$

Και με $VC(H) = 2d$, έχουμε:

$$m = O\left(\frac{d}{\varepsilon^2} \log \frac{1}{\delta}\right) = O\left(\frac{d}{\varepsilon^2} \log(d/\delta)\right)$$

Εδώ ο αριθμός δειγμάτων εξαρτάται πιο έντονα από το ε , καθώς πρέπει να καλύψουμε και την απόσταση ανάμεσα στη βέλτιστη υπόθεση της H και στην κατανομή των δεδομένων. Με βάση τα παραπάνω, βλέπουμε πως ο αλγόριθμος A συνεπάγεται την εξής δειγματική πολυπλοκότητα:

- Στην *realizable* περίπτωση:

$$m = O\left(\frac{d}{\varepsilon} \log \frac{1}{\delta}\right) = O\left(\frac{d}{\varepsilon} \log(d/\delta)\right)$$

- Στην *agnostic* περίπτωση:

$$m = O\left(\frac{d}{\varepsilon^2} \log \frac{1}{\delta}\right) = O\left(\frac{d}{\varepsilon^2} \log(d/\delta)\right)$$

Συμπερασματικά, όταν υποθέτουμε ότι υπάρχει υπόθεση που ταιριάζει τέλεια στα δεδομένα, χρειαζόμαστε λιγότερα δείγματα. Αντίθετα, όταν δεν υπάρχει τέτοια υπόθεση, πρέπει να χρησιμοποιήσουμε περισσότερα δείγματα για να έχουμε καλή απόδοση.