



[Κ17] Υπολογιστική Θεωρία Μηχανικής Μάθησης

Θεωρητικές Ασκήσεις

Ονοματεπώνυμο: Χολέβας Δημήτριος

Ακαδημαϊκό Έτος: 2024-25

6η Θεωρητική Άσκηση

(SGD για *Truncated Statistics*)

Εισαγωγή

Θεωρούμε κανονική κατανομή $N(\mu^*, 1)$ με άγνωστη μέση τιμή μ^* και γνωστή διακύμανση ίση με 1. Δεν έχουμε άμεση πρόσβαση σε δείγματα από αυτήν την κατανομή, αλλά παρατηρούμε μόνο δείγματα x τέτοια ώστε $x \geq 0$. Δηλαδή, έχουμε πρόσβαση στην περιορισμένη κατανομή $N_{\geq 0}(\mu^*, 1)$. Επιπλέον, υποθέτουμε ότι υπάρχει εκ των προτέρων γνώση για την τιμή της παραμέτρου: $|\mu^*| \leq B$.

Ορισμός της Συνάρτησης Κόστους

Θέλουμε να εκτιμήσουμε τη μ^* εφαρμόζοντας *SGD* στη συνάρτηση κόστους:

$$f(\mu) = \mathbb{E}_{x \sim N_{\geq 0}(\mu^*, 1)} \left[-\log \left(\frac{e^{-\frac{1}{2}(x-\mu)^2}}{\int_0^\infty e^{-\frac{1}{2}(z-\mu)^2} dz} \right) \right]$$

Αναλύουμε τον λογάριθμο και έχουμε:

$$f(\mu) = \mathbb{E} \left[\frac{1}{2}(x - \mu)^2 + \log \left(\int_0^\infty e^{-\frac{1}{2}(z-\mu)^2} dz \right) \right]$$

Δηλαδή:

$$f(\mu) = \frac{1}{2} \mathbb{E}_{x \sim N_{\geq 0}(\mu^*, 1)} [(x - \mu)^2] + \log Z(\mu), \quad \text{όπου } Z(\mu) = \int_0^\infty e^{-\frac{1}{2}(z-\mu)^2} dz$$

Αυτή είναι η αρνητική *log-likelihood* του μοντέλου με σεβασμό στη μ , δεδομένων των περιορισμένων δειγμάτων.

Κανονικοποίηση και Χρήση της $\Phi(\mu)$

Ορίζουμε $\phi(\mu) = \frac{1}{\sqrt{2\pi}}e^{-\mu^2/2}$ και $\Phi(\mu) = \Pr_{z \sim N(0,1)}[z \leq \mu]$ (cdf). Με αλλαγή μεταβλητής έχουμε:

$$Z(\mu) = \int_0^\infty e^{-\frac{1}{2}(z-\mu)^2} dz = \sqrt{2\pi} \cdot \Phi(\mu)$$

Άρα η τελική μορφή της $f(\mu)$ γίνεται:

$$f(\mu) = \frac{1}{2}\mathbb{E}[(x - \mu)^2] + \log \Phi(\mu)$$

Συμπεριφορά της $f(\mu)$ και Ιδιότητες

- Η $f(\mu)$ είναι **συνεχής** και **διαφορίσιμη** στο διάστημα $[-B, B]$, γιατί το τετράγωνο και η $\log \Phi(\mu)$ είναι και οι δύο *smooth* συναρτήσεις.
- Η $f(\mu)$ είναι επίσης **ισχυρά κυρτή** (*strongly convex*), επειδή το τετραγωνικό σφάλμα έχει κυρτότητα και το $\log \Phi(\mu)$ είναι κυρτή στο $(-\infty, 0]$ και αρκετά επίπεδη στο $[0, \infty)$. Για περιορισμένο διάστημα $[-B, B]$, αυτό αρκεί.
- Το **μοναδικό ελάχιστο** σημαίνει ότι υπάρχει μία και μόνο τιμή μ^* για την οποία η $f(\mu)$ είναι ελάχιστη.
- Όταν λέμε ότι η παράγωγος δεν αλλάζει απότομα, εννοούμε ότι η $f(\mu)$ είναι *L-Lipschitz differentiable*, δηλαδή: $\|\nabla f(\mu_1) - \nabla f(\mu_2)\| \leq L \cdot |\mu_1 - \mu_2|$. Αυτό σημαίνει ότι το σχήμα της δεν έχει αιχμές ή ασυνέχειες και επομένως η σύγκλιση με *SGD* είναι εφικτή.

Η στοχαστική εκτίμηση της παραγώγου της $f(\mu)$ δίνεται από:

$$g_t = \nabla_\mu \left(\frac{1}{2}(x_t - \mu)^2 + \log \Phi(\mu) \right) = (\mu - x_t) + \frac{\phi(\mu)}{\Phi(\mu)}$$

Οπότε συνεχίζουμε ως εξής:

$$\mu_{t+1} = \Pi_{[-B, B]}(\mu_t - \eta g_t)$$

όπου $\Pi_{[-B, B]}$ είναι η **προβολή στο διάστημα** $[-B, B]$:

$$\Pi_{[-B, B]}(x) = \min\{\max\{x, -B\}, B\}$$

Αυτό εξασφαλίζει ότι πάντα θα ισχύει $\mu_t \in [-B, B]$, άρα σε κάθε βήμα παραμένουμε εντός του έγκυρου χώρου αναζήτησης.

Ρυθμός Σύγκλισης και Αριθμός Επαναλήψεων

Σύμφωνα με τη θεωρία της στοχαστικής βαθμιδωτής καθόδου με προβολή, όταν η συνάρτηση είναι ισχυρά κυρτή, ισχύει:

$$\mathbb{E}[\|\mu_T - \mu^*\|] \leq \varepsilon \quad \text{αν } T = O\left(\frac{1}{\varepsilon^2}\right)$$

όπου ο αριθμός επαναλήψεων (και άρα παρατηρήσεων x_t) που απαιτούνται είναι αντιστρόφως ανάλογος του τετράγωνου της ακρίβειας ε . Αυτό προκύπτει από την ανάλυση σύγκλισης στη στοχαστική βελτιστοποίηση, όταν οι βαθμίδες έχουν φραγμένη διακύμανση και ο χώρος των λύσεων είναι περιορισμένος.

Συμπέρασμα

Με βάση όλα τα παραπάνω, διαπιστώνουμε τα εξής:

- Η $f(\mu)$ είναι συνεχής, διαφορίσιμη και έχει μοναδικό ελάχιστο στο διάστημα $[-B, B]$.
- Η παράγωγός της είναι *Lipschitz*, άρα επιτρέπει αποδοτική βελτιστοποίηση με *SGD*.
- Η χρήση προβολής εξασφαλίζει ότι κάθε ενημέρωση παραμένει εντός του $[-B, B]$.
- Συνεπώς, εφαρμόζοντας στοχαστική καθοδική κίνηση βαθμίδας (*SGD*) με κατάλληλο βήμα εκμάθησης και $T = O(1/\varepsilon^2)$ δείγματα από την $N_{\geq 0}(\mu^*, 1)$, μπορούμε να εκτιμήσουμε τη μ^* με προσέγγιση σφάλματος ε .